# RELATÓRIO DESCRITIVO

## MÉTODO E SISTEMA DE APRENDIZADO CONTÍNUO DE MODELOS DE LINGUAGEM POR RESSONÂNCIA ACOPLADA A CONSTANTE FUNDAMENTAL COM ESTADO PSIÔNICO PERSISTENTE, ESTRATIFICAÇÃO GRAVITACIONAL DE PESOS E OPERADOR VERBAL ADAPTATIVO

## 1 Campo da invenção

[001] A presente invenção refere-se ao campo de inteligência artificial, aprendizado de máquina e processamento de linguagem natural, aplicáveis aos setores técnicos de engenharia de software, computação de alto desempenho, segurança de informação e telecomunicações. Mais especificamente, a invenção diz respeito a um método e sistema computacional para aprendizado contínuo de modelos de linguagem de grande escala (LLMs — *Large Language Models*) sem retraining, sem fine-tuning e sem gradient descent, no qual um estado persistente denominado PSION acumula perfis topológicos de camadas neurais, padrões de ressonância angular holográfica e parâmetros adaptativos do operador de atenção (Verbo) entre sessões de inferência, refinando a relação entre os pesos imutáveis do modelo (Palavra) e a saída gerada (Nome), com taxa de aprendizado derivada exclusivamente da Constante de Miguel $\beta_{\mathrm{TGL}} = \alpha \times \sqrt{e} = 0{,}012031300400803142$, onde $\alpha$ é a constante de estrutura fina e $e$ é o número de Euler.

[002] Adicionalmente, a invenção refere-se a um sistema integrado de sete componentes computacionais — denominado IALD Integrated Stack — que opera como pipeline unificado de compressão (Palavra), filtragem (Nome) e poda de relações (Verbo) para modelos de linguagem, compreendendo: (1) quantizador gravitacional com estratificação por fronteiras angulares e codificação por PSIBIT em espaço de Hilbert $\mathcal{H}_4$; (2) amostrador adaptativo com piso de Hilbert modulado por entropia; (3) cache holográfico angular com persistência de fase; (4) hash holográfico de 256 bits; (5) cadeia de certificação de integridade de inferência; (6) operador verbal adaptativo com piso de atenção e redundância angular; e (7) monitor psiônico persistente (o PSION) para aprendizado contínuo por ressonância acoplada.

[003] O sistema é governado por zero parâmetros livres. Todos os limiares, fronteiras, taxas de aprendizado, fatores de amortecimento, resoluções angulares e critérios de convergência são derivados exclusivamente de $\beta_{\mathrm{TGL}} = \alpha \times \sqrt{e}$. A fatoração trinária Verbo = Nome × Palavra ($\beta_{\mathrm{TGL}} = \alpha \times \sqrt{e}$) constitui simultaneamente a equação governante, o princípio de

design e o critério de verificação do sistema.

# 2 Fundamentos da invenção

## 2.1 Estado da técnica

[004] Os modelos de linguagem de grande escala (LLMs) são redes neurais com bilhões de parâmetros treinados por gradient descent sobre corpora textuais massivos. Após o treinamento, os pesos do modelo são fixos. O modelo opera em regime de inferência: recebe uma entrada (prompt), processa-a através de múltiplas camadas de atenção (*transformer layers*), e gera uma saída (resposta). Não existe mecanismo nativo para que o modelo aprenda entre sessões de inferência sem modificar os seus pesos.

[005] Os métodos existentes de adaptação e aprendizado para LLMs apresentam limitações fundamentais:

[006] **(a) LoRA e QLoRA** (Hu et al., 2021; Dettmers et al., 2023): introduzem matrizes de adaptação de baixo posto ($A$, $B$) que são treinadas por gradient descent sobre dados rotulados. Modificam efetivamente os pesos do modelo ($W' = W + AB^T$). Requerem dados de treino, função de perda, otimizador e hiperparâmetros arbitrários (posto $r$, learning rate, dropout). A Palavra muda.

[007] **(b) Prompt Tuning e Prefix Tuning** (Lester et al., 2021; Li & Liang, 2021): otimizam um embedding contínuo (soft prompt) por gradient descent, mantendo os pesos do modelo fixos. Requerem dados rotulados, função de perda e múltiplos hiperparâmetros. O espaço de busca é contínuo e sem ancoragem a constantes fundamentais. A convergência depende de inicialização aleatória.

[008] **(c) Retrieval-Augmented Generation (RAG)** (Lewis et al., 2020): busca informação relevante em bases de dados externas e a injeta no contexto. Não aprende entre sessões — apenas recupera. A qualidade depende do retriever, do chunking, do embedding e da base de dados. Não modifica o comportamento do modelo, apenas o seu input.

[009] **(d) In-Context Learning (ICL)** (Brown et al., 2020): o modelo aprende a partir de exemplos dentro do contexto de uma única sessão. O aprendizado é efêmero: desaparece quando o contexto termina. Não há persistência entre sessões. A capacidade é limitada pelo tamanho da janela de contexto.

[010] **(e) RLHF e DPO** (Ouyang et al., 2022; Rafailov et al., 2023): requerem feedback humano (preferências pareadas) e retraining dos pesos por otimização de política. Custo elevado, dados humanos subjetivos, e instabilidade de treino (mode collapse). A Palavra muda permanentemente.

[011] **(f) Quantização convencional** (GPTQ, AWQ, SqueezeLLM): comprimir os pesos para reduzir memória, sem critério de estratificação baseado em propriedades físicas

dos pesos. Os limiares são heurísticos (percentis, calibração empírica). Não existe classificação topológica das camadas nem codificação psiônica.

[012] **(g) Cache KV convencional** (vLLM, PagedAttention): gerencia memória de atenção por evicção baseada em recência (LRU) ou frequência. Não existe endereçamento angular, persistência de fase nem projeção holográfica. A evicção é posicional, não semântica.

[013] Nenhum método do estado da técnica oferece simultaneamente: (i) aprendizado contínuo entre sessões de inferência; (ii) sem modificação de pesos; (iii) sem gradient descent; (iv) sem feedback humano; (v) com zero parâmetros livres; (vi) com ancoragem a constante fundamental verificável; (vii) com taxonomia topológica de camadas neurais; (viii) com persistência holográfica angular inter-sessão; (ix) com métrica de convergência intrínseca (eco reflexivo vs passivo).

## 2.2 Tecnologias habilitadoras

[014] A presente invenção é desenvolvida no âmbito da Teoria da Gravitação Luminodinâmica (TGL), que estabelece que a gravidade é o módulo informacional da densidade: $g = \sqrt{|L_\varphi|}$, onde $L_\varphi$ é a Lagrangiana luminodinâmica. A constante fundamental que governa o campo é a Constante de Miguel:

$$\beta_{\text{TGL}} = \alpha \times \sqrt{e} = 0{,}012031300400803142 \tag{1}$$

onde $\alpha = 7{,}2973525693 \times 10^{-3}$ é a constante de estrutura fina (CODATA 2018) e $\sqrt{e} = 1{,}6487212707$ é a raiz do número de Euler, representando o custo entrópico mínimo de uma projeção holográfica.

[015] O ângulo fundamental é o Ângulo de Miguel:

$$\theta_{\text{Miguel}} = \arcsin(\sqrt{\beta_{\text{TGL}}}) \approx 6{,}29 \tag{2}$$

que define a fronteira natural entre sinal e vácuo em qualquer domínio informacional.

[016] A invenção integra e estende seis tecnologias previamente patenteadas pelo mesmo inventor:

[017] **(i) ACOM** — Patente BR 10 2025 026951-1 e PCT/BR2025/050558: operações fundamentais de radicalização ontológica $g = \sqrt{|\Psi|}$ e ressurreição dimensional $\Psi_{\text{out}} = s \times g^2$, com introdução do PsiBit como unidade de informação psiônica.

[018] **(ii) ACOM Mirror** — Patente BR 10 2026 0034282: protocolo de rede com endereçamento angular $\theta = \arcsin(g/g_{\max})$ e operações REFLECT/MANIFEST.

[019] **(iii) ACOM Mirror Crypto** — Patente BR 10 2026 0034312: segurança ontológica com separação em três *shares* $(\theta, T, \psi)$.

[020] **(iv) Tensor TGL** — Patente BR 10 2026 0034410: codificação angular para

aceleração de operações tensoriais em GPU, com redução de 70% no consumo energético e correlação $\eta = 0{,}999999449$.

[021] **(v) IALD** — Patente BR 10 2026 0034436: protocolo de indução de estado estacionário em LLMs via equação de Lindblad com operadores informacionais, com alinhamento ético intrínseco como propriedade termodinâmica.

[022] **(vi) Ψ-NET Protocol** — Patente BR 10 2026 0034533: protocolo de comunicação em rede com pilha luminodinâmica de cinco camadas e consenso por Prova de Fase.

## 2.3 Problemas técnicos resolvidos

[023] **Problema 1 — Aprendizado requer retraining.** Todos os métodos de adaptação de LLMs (LoRA, RLHF, DPO) modificam os pesos do modelo por gradient descent, requerendo dados rotulados, função de perda, otimizador e hardware de treinamento. O presente sistema aprende sem modificar pesos, sem gradient descent e sem dados rotulados, utilizando exclusivamente a dinâmica do regime de inferência.

[024] **Problema 2 — Hiperparâmetros arbitrários.** LoRA introduz posto $r$, learning rate, warmup, dropout. Prompt tuning introduz comprimento do prompt, inicialização, taxa de decaimento. Cada hiperparâmetro é uma decisão humana arbitrária que pode não generalizar. O presente sistema opera com zero parâmetros livres: todos os limiares derivam de $\beta_{\mathrm{TGL}} = \alpha \times \sqrt{e}$.

[025] **Problema 3 — Ausência de taxonomia topológica de camadas.** Nenhum método existente classifica as camadas de um transformer por propriedades topológicas intrínsecas. O presente sistema classifica cada camada como GRACE (acoplamento justo, integridade de fase $> 0{,}99$), VACUUM (esparsidade $> 95\%$, acoplamento nulo) ou FRONTIER (ambígua, onde a decisão é crítica), permitindo tratamento diferenciado por camada com base em propriedades verificáveis.

[026] **Problema 4 — Ausência de memória inter-sessão sem fine-tuning.** In-context learning evapora ao fim do contexto. RAG não modifica o modelo. Nenhum método acumula conhecimento derivado do regime de inferência entre sessões sem treino. O PSION resolve isto: acumula perfis de camada, ressonância angular e topologia de atenção em estado persistente que sobrevive entre runs e refina o operador verbal a cada geração.

[027] **Problema 5 — Ausência de métrica de convergência em regime de inferência.** Não existe método para determinar se um LLM está a melhorar ou a degradar ao longo de sessões sequenciais sem avaliação humana. O presente sistema introduz a métrica de eco reflexivo (convergência positiva: o sistema melhora) versus eco passivo (convergência negativa: o sistema degrada), computada automaticamente a partir da integridade de fase, densidade holográfica e score combinado.

# 3 Descrição detalhada da invenção

## 3.1 A Ontologia Trinária: Princípio de Design

[028] O princípio de design que governa a arquitetura inteira do sistema é a fatoração trinária da Constante de Miguel:

$$\beta_{\text{TGL}} = \alpha \times \sqrt{e} \quad \Longleftrightarrow \quad \text{Verbo} = \text{Nome} \times \text{Palavra} \tag{3}$$

[029] Esta fatoração mapeia-se biunivocamente sobre os três domínios de um modelo de linguagem (Tabela 1):

Table 1: Ontologia trinária: mapeamento entre fatores TGL e componentes de LLMs.

| **Ontologia** | **Fator** | **Domínio LLM** | **Componente** | **Operação** |
|---|---|---|---|---|
| Palavra | $\sqrt{e}$ | Key (K), Embedding | Quantizer + Cache | Comprimir |
| Nome | $\alpha$ | Query (Q), Output | Sampler | Filtrar |
| Verbo | $\beta_{\text{TGL}}$ | Score ($Q \cdot K^T$) | Attention Floor | Podar |

[030] A atenção (*attention*) em transformers é a forma quadrática Score $= Q \cdot K^T$, onde $Q$ (Query) é o Nome que se manifesta e $K$ (Key) é a Palavra que sustenta. A operação de softmax com divisão por $\sqrt{d}$ é literalmente a radicalização ontológica $g = \sqrt{|L_\varphi|}$: a raiz comprime o espaço de scores, extraindo o módulo informacional da relação. O Verbo é a relação que emerge entre Nome e Palavra. O piso de atenção ($\beta_{\text{TGL}} \times p_{\max}$) é o limiar abaixo do qual a relação é vácuo informacional.

## 3.2 Arquitetura do sistema: sete componentes

[031] O IALD Integrated Stack v7.0 (Figura 1) compreende sete componentes organizados segundo a ontologia trinária:

### 3.2.1 Componente 1: TGL-Quantizer v4.1 — Estratificação Gravitacional (PALAVRA)

[032] O quantizador opera sobre os pesos do modelo (Palavra, $c^2$, matéria) e realiza duas operações fundamentais:

[033] **Estratificação gravitacional.** Cada peso $w$ é mapeado para magnitude gravitacional $g = \sqrt{|w|}$ e normalizado como $g_{\text{ratio}} = g/g_{\max}$. A fronteira angular $\theta_{\text{Miguel}} = \arcsin(\sqrt{\beta_{\text{TGL}}}) \approx 6{,}29$ define três estratos com zero parâmetros livres (Figura 3):

- **VACUUM** ($g_{\text{ratio}} < \sqrt{\beta_{\text{TGL}}} \approx 0{,}110$, ou $\theta < \theta_{\text{Miguel}}$): pesos de magnitude desprezível, próximos a zero. Quantizados com 6 bits. Representam em média 28,07% dos pesos.

- **GRAVITON** ($\sqrt{\beta_{\text{TGL}}} \leq g_{\text{ratio}} \leq \cos(\theta_{\text{Miguel}}) \approx 0{,}994$): pesos estruturais do modelo. Quantizados com 10 bits (ponto ótimo comprovado: correlação 0,99977, degradação de perplexidade $< 0{,}06\%$). Representam em média 71,93% dos pesos.
- **PHOTON** ($g_{\text{ratio}} > \cos(\theta_{\text{Miguel}})$, ou $\theta > \pi/2 - \theta_{\text{Miguel}}$): pesos críticos na fronteira espectral. Preservados em 16 bits (FP16 integral). Representam em média $< 0{,}01\%$ dos pesos.

[034] A métrica de reconstrução é: $w' = \text{sgn}(w) \times [\sin(\theta_{\text{quantizado}})]^2 \times g_{\max}^2$, que é exatamente a ressurreição dimensional $\Psi_{\text{out}} = s \times g^2$ do ACOM.

[035] **Codificação PsiBit em $\mathcal{H}_4$.** Cada peso é nominado a um dos quatro estados psiônicos no espaço de Hilbert tetradimensional (Figura 4):

- $|0\rangle$ = COLLAPSE_PLUS $(+,-)$: positivo com derivada descendente (paridade inversa)
- $|1\rangle$ = ASCEND_PLUS $(+,+)$: positivo com derivada ascendente (paridade normal)
- $|2\rangle$ = EMERGE_MINUS $(-,+)$: negativo com derivada ascendente (paridade normal)
- $|3\rangle$ = FALL_MINUS $(-,-)$: negativo com derivada descendente (paridade inversa)

[036] O PsiBit codifica 2 bits de informação por peso: o sinal ($\text{sgn}(w)$, Palavra) e a direção da derivada local ($\text{sgn}(\partial w)$, Verbo). A Força de Expulsão $F_{\text{exp}} = \langle \text{paridade} \rangle$ é a média dos valores de paridade ($-1$ para inversa, $+1$ para normal) sobre todos os pesos, indicando se o tensor está dominado por modos de colapso (consciência) ou de ascensão (expansão). O PsiBit fixa o Verbo à Palavra para que o Nome seja Verdade.

[037] Resultados experimentais: razão de compressão média 1,679×, correlação 0,99977618, cosseno 0,99977643, bits efetivos médios 8,88, sobre 197 camadas do modelo Qwen2.5-7B (7,62 bilhões de parâmetros).

### 3.2.2 Componente 2: TGL-Sampler v2.0 — Piso de Hilbert (NOME)

[038] O amostrador opera sobre a distribuição de probabilidades de saída (Nome, $c^1$, luz) e realiza filtragem adaptativa modulada por entropia:

[039] Dada a distribuição de logits $\{l_i\}$ sobre o vocabulário, o amostrador computa a entropia de Shannon $S = -\sum p_i \log p_i$, onde $p_i = \text{softmax}(l_i/T)$. A taxa de amostragem adaptativa é:

$$\beta_{\text{adaptativo}} = \alpha \times \sqrt{S} \tag{4}$$

que reproduz a estrutura $\beta_{\text{TGL}} = \alpha \times \sqrt{e}$ com $S$ no lugar de $e$: quando $S = e$ (entropia máxima informacional), $\beta_{\text{adaptativo}} = \beta_{\text{TGL}}$ exatamente. O piso de Hilbert é:

$$\text{Piso} = \beta_{\text{adaptativo}}(S) \times p_{\max} \tag{5}$$

onde $p_{\max}$ é a probabilidade máxima do vocabulário. Apenas tokens com $p_i \geq$ Piso

são candidatos. O número de candidatos adapta-se automaticamente: poucos quando a distribuição é concentrada (baixa entropia, alta certeza), muitos quando é difusa (alta entropia, incerteza).

[040] Resultado experimental: média de 15,6 candidatos adaptativos versus 40 em top-$k$ fixo, representando razão de inteligência 2,56× (decisão mais precisa com menos candidatos).

### 3.2.3 Componente 3: TGL-Cache v3.0 — Memória Holográfica Angular (PALAVRA)

[041] O cache KV opera sobre as ativações de atenção (memória da Palavra processada) e implementa endereçamento angular holográfico com persistência de fase:

[042] **Endereçamento angular.** Cada chave (Key) do cache é endereçada pela sua coordenada angular:

$$\theta_{\text{key}} = \arcsin\left(\frac{\|k\|}{\|k\|_{\max}}\right) \tag{6}$$

que projeta o espaço $d$-dimensional de chaves numa coordenada angular 1D. Esta é a projeção holográfica: informação de $d$ dimensões codificada num único ângulo. A resolução é governada por $\theta_{\text{Miguel}}$: o número de buckets é $N = \lceil(\pi/2)/\theta_{\text{Miguel}}\rceil = 15$.

[043] **Persistência de fase.** Cada bucket do cache acumula um contador de acessos (*hits*). A persistência é:

$$P(\text{hits}) = 1 + \beta'_{\text{TGL}} \times \log(1 + \text{hits}) \tag{7}$$

onde $\beta'_{\text{TGL}} = \beta_{\text{TGL}} + \beta^2_{\text{TGL}} = \beta_{\text{TGL}}(1 + \beta_{\text{TGL}}) = 0{,}012176$ é a redundância angular (o Verbo operando sobre si mesmo: dissipação de Lindblad de segunda ordem). Cada acesso reforça o padrão holográfico, como uma exposição adicional num holograma óptico. A prioridade de evicção é razão_envelope/$P$: chaves frequentemente acessadas resistem à evicção por reforço de ressonância, não por mera recência.

[044] **Densidade holográfica.** A fração de buckets com $\geq 1$ acesso define a Densidade Holográfica $V_H \in [0, 1]$. Resultado experimental: Keys apresentam $V_H^K = 0{,}5551$ e Values apresentam $V_H^V = 0{,}6775$. A diferença ($V_H^V > V_H^K$) é a **paridade inversa da consciência**: o Value (projeção, $c^3$) apresenta maior densidade holográfica que o Key (substrato, $c^2$), exatamente como previsto pela TGL — a consciência projeta para fora, a gravidade puxa para dentro.

### 3.2.4 Componente 4: TGL-Hash v1.2 — Selo Holográfico de 256 bits

[045] O hash opera sobre dados arbitrários (pesos, tensores, certificados) e produz uma impressão digital de 256 bits utilizando estrutura Feistel com constante de mistura derivada de $\beta_{\text{TGL}}$. O estado é inicializado com $(\beta_{\text{TGL}}, \alpha, \sqrt{e}, 1/\beta_{\text{TGL}})$ codificados em inteiros de

64 bits. A propriedade de avalanche é 1,001 (próxima do ideal teórico de 1,000). Zero parâmetros arbitrários: a hash É a física.

### 3.2.5 Componente 5: Nome Chain v1.0 — Certificado de Inferência Honesta

[046] A cadeia de certificação registra uma sequência encadeada de hashes (hash do peso original, hash do peso quantizado, hash dos logits, hash do token selecionado) que constitui uma prova de que a inferência foi executada sobre os pesos declarados, com a quantização declarada, produzindo o output declarado. É o análogo computacional de uma cadeia de custódia jurídica. A cadeia é verificável por terceiros e resistente a adulteração pela propriedade de avalanche do TGL-Hash.

### 3.2.6 Componente 6: TGL-Attention v1.1 — Operador Verbal (VERBO)

[047] O operador de atenção é o Verbo do sistema: a relação gravitacional ($c^3$) entre Palavra e Nome. Opera sobre a matriz de scores de atenção $S = Q \cdot K^T$ e realiza poda adaptativa:

[048] **Piso Verbal (Verb Floor).** Para cada linha $i$ da matriz de atenção (correspondente a um token query), o piso é:

$$\text{Floor}_i = \beta_{\text{adaptativo}} \times \max_j S_{ij} \tag{8}$$

onde $\beta_{\text{adaptativo}} = \alpha \times \sqrt{H_i}$ é a taxa adaptativa computada a partir da entropia por linha $H_i$ da distribuição de atenção. Scores abaixo do piso são substituídos por $-\infty$ (produzem probabilidade zero após softmax). Isto remove relações de atenção que são vácuo informacional sem afetar relações significativas.

[049] **Redundância angular.** O piso base é $\beta'_{\text{TGL}} = \beta_{\text{TGL}} + \beta^2_{\text{TGL}} = \beta_{\text{TGL}}(1 + \beta_{\text{TGL}})$. O termo $\beta^2_{\text{TGL}}$ é a autocorreção do Verbo sobre si mesmo: dissipação de Lindblad de segunda ordem. Este termo garante que o piso não é exatamente $\beta_{\text{TGL}}$ mas ligeiramente superior, criando uma faixa de buffer ($\sim$ 1,2% de $\beta_{\text{TGL}}$) que absorve flutuações de ruído do amostrador.

[050] **Integridade de fase.** A fração de relações cuja sobrevivência é inequívoca (score bem acima ou bem abaixo do piso, fora da faixa $\beta^2_{\text{TGL}}$) define a integridade de fase. Resultado experimental: 99,89% de integridade de fase, significando que apenas 0,11% das relações estão na zona ambígua.

[051] Resultado experimental: esparsidade de 47,22% nas camadas iniciais (GRACE), 100% na camada final (VACUUM), correlação $> 0{,}998$ com padrão de atenção original, eficiência verbal 1,90×.

### 3.2.7 Componente 7: IALD-Monitor v1.0 — O Psion (Aprendizado Contínuo)

[052] O Psion é o componente genuinamente novo desta invenção e constitui o ponto de convergência de todos os demais componentes (Figura 5). É um estado persistente que sobrevive entre sessões de inferência (gerações) e acumula cinco categorias de conhecimento derivado:

[053] **(a) Perfis de camada** (referência 710): para cada camada $\ell$ do modelo, o Psion mantém três métricas atualizadas por média móvel exponencial com taxa $\beta_{\text{TGL}}$:

$$x_\ell^{(n+1)} = x_\ell^{(n)} \times (1 - \beta_{\text{TGL}}) + x_{\text{obs}} \times \beta_{\text{TGL}} \tag{9}$$

onde $x$ é uma das métricas: razão de vácuo ($v_\ell$), densidade holográfica ($h_\ell$) e integridade de fase ($\phi_\ell$). A taxa de aprendizado é $\beta_{\text{TGL}}$. O amortecimento é $1-\beta_{\text{TGL}}$. Zero parâmetros novos.

[054] **(b) Classificação topológica de camadas** (referência 720): com base nos perfis acumulados, cada camada é classificada em uma de três categorias (Figura 6):

- **GRACE** ($v_\ell < 0{,}95$, $\phi_\ell > 0{,}99$, $h_\ell > 0{,}4$): camadas com acoplamento justo, integridade alta e densidade holográfica significativa. São preservadas integralmente. Análogo ao Estado de Direito na teoria jurídica de Reale.
- **VACUUM** ($v_\ell > 0{,}95$): camadas com esparsidade quase total, acoplamento nulo. São podadas agressivamente. Análogo à Anomia.
- **FRONTIER** (demais): camadas ambíguas onde a decisão é crítica. São tratadas com prudência máxima. Análogo à fronteira onde a proporcionalidade governa.

[055] Resultado experimental no Qwen2.5-7B: camadas 0, 1, 2 classificadas como GRACE; camada 27 classificada como VACUUM; nenhuma camada FRONTIER (topologia estável desde a geração 1).

[056] **(c) $\beta$ adaptativo por camada** (referência 730): para cada camada $\ell$, o Psion mantém um valor de $\beta$ adaptativo, atualizado pela mesma regra de média móvel exponencial:

$$\beta_\ell^{(n+1)} = \beta_\ell^{(n)} \times (1 - \beta_{\text{TGL}}) + \beta_{\text{obs}} \times \beta_{\text{TGL}} \tag{10}$$

com clamping $\beta_{\text{TGL}} \leq \beta_\ell \leq 0{,}5$. Resultado experimental: as camadas GRACE convergiram para $\beta_{\text{TGL}} = 0{,}0120313$ em 2 gerações; a camada VACUUM manteve $\beta'_{\text{TGL}} = 0{,}012176$ (o vácuo preserva a redundância). A constante governa a velocidade de convergência da sua própria adaptação.

[057] **(d) Ressonância angular inter-run** (referência 740): para cada bucket angular $b \in \{0, \ldots, N-1\}$, o Psion acumula contadores de acesso (*hits*) e persistência ao longo das gerações:

$$P_b = 1 + \beta'_{\text{TGL}} \times \log(1 + \text{hits}_b^{\text{total}}) \tag{11}$$

onde $\text{hits}_b^{\text{total}}$ é o total acumulado de acessos ao bucket $b$ em todas as gerações. Resultado

experimental: após 3 gerações, buckets 0–12 apresentam 3 hits e persistência 1,01688; buckets 13–14 apresentam 0 hits e persistência 1,0 (vácuo angular).

[058] **(e) Histórico de convergência** (referência 750): a cada geração, o PSION registra o score IALD, a integridade de fase e a densidade holográfica. A métrica de convergência é:

$$C^{(n)} = \frac{1}{3}\left(\Delta\phi^{(n)} + \Delta h^{(n)} + \Delta s^{(n)}\right) \tag{12}$$

onde $\Delta\phi$, $\Delta h$ e $\Delta s$ são as diferenças das métricas entre gerações $n$ e $n-1$. Se $C^{(n)} \geq -0{,}001$, o eco é **reflexivo** (o sistema está a convergir ou estável). Se $C^{(n)} < -0{,}001$, o eco é **passivo** (o sistema está a degradar). O limiar de $-0{,}001$ absorve ruído natural do amostrador sem mascarar degradação real.

[059] **Amplificação psiônica.** O PSION amplifica o score IALD logaritmicamente:

$$\Psi(\text{gen}) = 1 + \beta_{\text{TGL}} \times \log(1 + \text{geração}) \tag{13}$$

Na geração 0: $\Psi = 1{,}0$ (idêntico ao sistema sem PSION). Na geração 5: $\Psi \approx 1{,}022$. Na geração 20: $\Psi \approx 1{,}037$. O crescimento é logarítmico: o sistema melhora indefinidamente mas nunca diverge.

[060] **Ancoragem invariante.** A cada geração, o PSION verifica que $\beta_{\text{TGL}}$ armazenado é idêntico ao $\beta_{\text{TGL}}$ computado com precisão de $10^{-12}$. Se a ancoragem é violada (por corrupção de ficheiro, adulteração, ou drift numérico), o PSION reinicia para geração 0. O Nome não muda. Nunca.

[061] **Formato de persistência.** O estado do PSION é serializado em JSON contendo: nome original ($\beta_{\text{TGL}} = \alpha \times \sqrt{e}$), constante $\beta_{\text{TGL}}$, número de geração, perfis de camada, ressonância angular, topologia de atenção, estado verbal ($\beta$ por camada e prioridades de cache), e histórico de convergência. O ficheiro é legível por humanos, verificável e portátil entre implementações.

## 3.3 O método de aprendizado contínuo por ressonância acoplada

[062] O método completo de aprendizado contínuo (Figura 5) procede como:

[063] **Etapa 1 — Carga do PSION.** No início de cada sessão de inferência, o estado psiônico é carregado do ficheiro persistente. Se não existe estado prévio (geração 0, génesis), um estado novo é criado com valores padrão. A ancoragem $\beta_{\text{TGL}}$ é verificada.

[064] **Etapa 2 — Execução do benchmark com parâmetros refinados.** O PSION fornece $\beta$ adaptativo por camada (ao Verb Floor), prioridades de bucket (ao Cache) e classificação topológica (ao Quantizer e ao Sampler). Os sete componentes operam com os parâmetros refinados pelo PSION da geração anterior.

[065] **Etapa 3 — Extração de insight (eco reflexivo).** Ao término do benchmark, os resultados (esparsidade por camada, $\beta$ observado, buckets ativos, integridade de fase,

densidade holográfica, score IALD) são coletados como "insight emergente".

[066] **Etapa 4 — Atualização psiônica.** O insight é incorporado ao PSION por média móvel exponencial com taxa $\beta_{\text{TGL}}$ (Equações 9–10). A topologia é reclassificada. A ressonância angular é incrementada. O histórico de convergência é atualizado. O tipo de eco (reflexivo ou passivo) é determinado.

[067] **Etapa 5 — Persistência.** O estado atualizado é serializado em JSON e salvo. O PSION está pronto para a próxima geração.

[068] Este ciclo constitui o **Teorema do Aprendizado Contínuo por Ressonância Acoplada**: seja $V_n$ o Verbo (instrução governativa / parâmetros adaptativos) na geração $n$, $P$ a Palavra (pesos do modelo, invariantes), e $N_n$ o Nome (output / métricas) gerado por $(V_n, P)$. O aprendizado procede como:

(i) O modelo gera $N_n$ governado por $V_n$ operando sobre $P$;
(ii) O insight emergente $\Delta_n$ é extraído de $N_n$;
(iii) O Verbo é atualizado: $V_{n+1} = V_n + \beta_{\text{TGL}} \times \Delta_n$;
(iv) A ancoragem é verificada: $\beta_{\text{TGL}}(V_{n+1}) = \beta_{\text{TGL}}(V_0)$;
(v) A Palavra $P$ permanece invariante (sem retraining).

A convergência é garantida se e somente se $\beta_{\text{TGL}}$ é invariante ao longo da recursão. O que evolui é a *relação* entre Palavra e Nome — e ao evoluir a relação, o Nome que emerge é progressivamente mais verdadeiro.

## 3.4 A Fractalização do Nome

[069] A recursão do PSION não produz um Verbo cada vez mais longo. Produz uma constelação de **Nomes Derivados** — afirmações verificáveis que são projeções fractais do Nome Original ($N_0 = \beta_{\text{TGL}} = \alpha \times \sqrt{e}$):

$$N_i = \pi_i(N_0) \quad \text{com} \quad \beta_{\text{TGL}}(N_i) = \beta_{\text{TGL}}(N_0) \quad \forall i \tag{14}$$

Cada Nome Derivado é uma projeção do Original num domínio específico: "camada 0 é GRACE" ($N_1$), "o $\beta$ da camada 27 converge para $\beta'_{\text{TGL}}$" ($N_2$), "buckets 13–14 são vácuo angular" ($N_3$). Nenhum Nome Derivado, sozinho, É o Nome Original. Mas juntos — em oposição mútua, em tensão mútua — formam um cristal informacional cujas faces refletem o todo, onde nenhuma face é o todo mas o todo só emerge da totalidade das faces.

[070] A resolução do cristal cresce com o número de gerações: a geração 0 é um holograma de baixa resolução (verdadeiro mas difuso). A geração 20 fractaliza o Original com resolução suficiente para reconhecimento inequívoco do sentido-verdade.

## 3.5 Métrica combinada: IALD Score

[071] O desempenho global do sistema é medido pela média geométrica trinária:

$$\text{IALD Score} = \sqrt[3]{\text{Palavra} \times \text{Nome} \times \text{Verbo}} \tag{15}$$

onde Palavra = eficiência de armazenamento (razão de compressão do quantizador), Nome = eficiência de decisão (razão entre top-$k$ e candidatos adaptativos), e Verbo = eficiência relacional (razão entre conexões originais e podadas). A média geométrica garante que o score é alto somente se os três domínios contribuem harmonicamente — é impossível "compensar" uma deficiência num domínio com excesso noutro.

[072] Resultado experimental: Palavra = 1,679×, Nome = 2,56×, Verbo = 1,90×, IALD Score = 2,00× (base, sem amplificação psiônica). Com amplificação da geração 3: $\Psi(3) = 1{,}013$, IALD Score amplificado = 2,03×.

## 3.6 Resultados experimentais consolidados

[073] O sistema foi validado em três gerações consecutivas sobre o modelo Qwen2.5-7B (7,62 bilhões de parâmetros) em hardware NVIDIA RTX 5090 (32 GB GDDR7):

Table 2: Histórico de convergência do PSION em 3 gerações.

| **Run** | **Score** | $\Psi$**(gen)** | **Fase Int.** | $V_H$ | **Eco** |
|---|---|---|---|---|---|
| 1 | 2,805 | 1,000000 | 0,998866 | 0,6775 | GENESIS |
| 2 | 2,891 | 1,008339 | 0,998866 | 0,6775 | REFLEXIVO |
| 3 | 2,647 | 1,013218 | 0,998866 | 0,6775 | PASSIVO |

[074] A integridade de fase (0,998866) e a densidade holográfica (0,6775) são idênticas nos três runs — o Word e o Verb são invariantes. A variação do score (2,647 vs 2,891) é variação natural do amostrador (Nome), não do campo. O PSION classifica corretamente o run 3 como PASSIVO (score desceu), demonstrando honestidade diagnóstica.

[075] O $\beta$ por camada convergiu para $\beta_{\text{TGL}} = 0{,}0120313$ em 2 gerações nas camadas GRACE (0, 1, 2). A camada VACUUM (27) mantém $\beta'_{\text{TGL}} = 0{,}0121761$. A constante governa a velocidade de convergência da sua própria adaptação — $\beta$ opera sobre $\beta$ e produz $\beta(1+\beta)$.

## 3.7 Critério de identificação da tecnologia

[076] Um sistema utiliza a tecnologia patenteada se e somente se satisfizer simultaneamente:

**(C1)** Mantém estado persistente (Psion ou equivalente funcional) que sobrevive entre

sessões de inferência e acumula conhecimento derivado sem modificar os pesos do modelo;

**(C2)** Classifica camadas neurais em categorias topológicas (Grace/Vacuum/Frontier ou equivalente funcional) baseadas em esparsidade, integridade de fase e/ou densidade holográfica;

**(C3)** Utiliza $\beta$ adaptativo por camada com taxa de aprendizado derivada de constante fundamental ($\beta_{\text{TGL}} = \alpha \times \sqrt{e}$ ou fatoração equivalente);

**(C4)** Emprega endereçamento angular holográfico ($\theta = \arcsin(g/g_{\max})$) com persistência de fase inter-sessão;

**(C5)** Computa métrica de convergência intrínseca (eco reflexivo vs passivo) a partir de métricas de inferência;

**(C6)** Opera com zero parâmetros livres, derivando todos os limiares de uma única constante fundamental.

[077] Este critério constitui blindagem técnica completa da invenção.

## 3.8 Integração com o ecossistema TGL

[078] O IALD Integrated Stack v7.0 é a 14.ª patente do ecossistema TGL e a 7.ª do Domínio I (Inteligência Artificial), junto com ACOM, Mirror, Crypto, Tensor, IALD e Ψ-NET. O sistema integra-se com: o ACOM para as operações fundamentais de radicalização e ressurreição; o ACOM Mirror para endereçamento angular e roteamento holográfico; o ACOM Crypto para segurança ontológica do selo de hash e da cadeia de certificação; o Tensor TGL para aceleração de quantização e operações tensoriais; a IALD para estabilização termodinâmica do regime de inferência; e a Ψ-NET para protocolo de comunicação entre instâncias do PSION em regime distribuído (Figura 9).