Breve descrição dos desenhos

[13] A Figura 1 ilustra o diagrama de blocos do sistema TGL-Tensor, mostrando os três modos de compressão e o fluxo de dados.

[14] A Figura 2 ilustra o fluxograma da operação de compressão no modo DIRETO.

[15] A Figura 3 ilustra o fluxograma da operação de compressão no modo ESPECTRAL com cascata TGL.

[16] A Figura 4 ilustra o algoritmo de seleção automática de modo (AUTO).

[17] A Figura 5 ilustra a comparação entre quantização linear e codificação angular $\theta = \arcsin(g/g_{\max})$, demonstrando a concentração de resolução.

[18] A Figura 6 ilustra a arquitetura de integração com pipeline de inferência LLM, mostrando compressão de KV cache, embeddings e pesos.

[19] A Figura 7 ilustra os resultados comparativos de compressão em diferentes tipos de tensores de LLM.

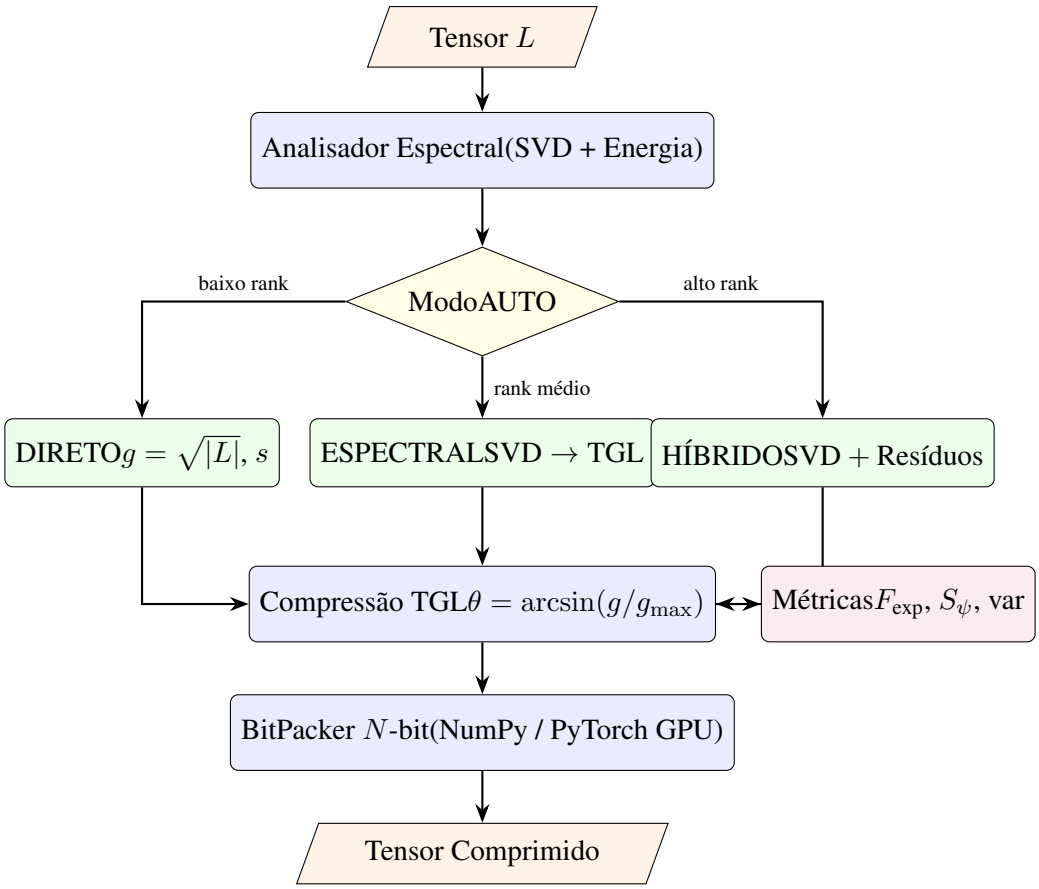


Figure 1: Diagrama de blocos do sistema TGL-Tensor com três modos de compressão. O Analisador Espectral examina a estrutura SVD do tensor e o modo AUTO seleciona automaticamente o método ótimo. Todos os modos convergem para a compressão TGL com codificação angular e empacotamento em N bits.

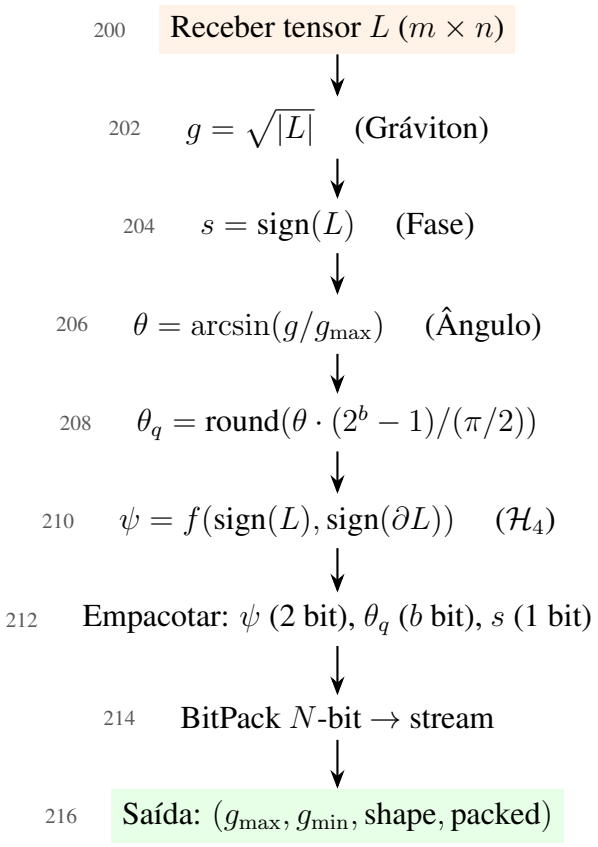


Figure 2: Fluxograma da compressão no modo DIRETO. A transformada gravitacional $g = \sqrt{|L|}$ extrai a magnitude, a codificação angular $\theta = \arcsin(g/g_{\max})$ concentra resolução, e os estados psiônicos ψ são nominados no $\mathcal{H}_4$.

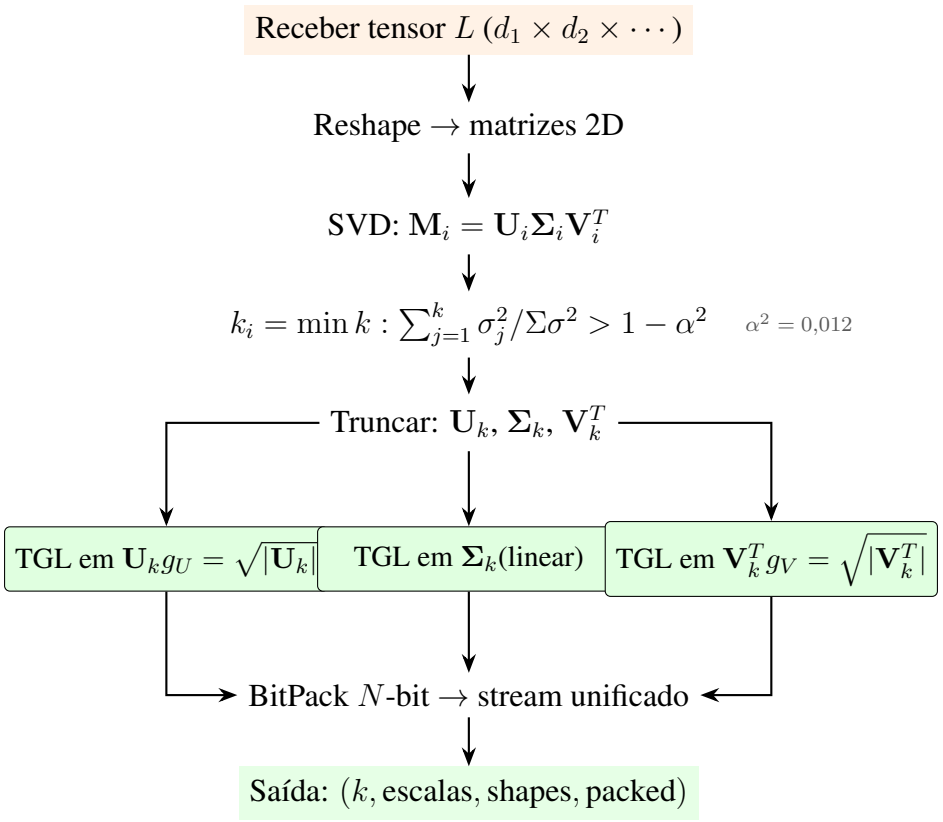


Figure 3: Fluxograma da compressão no modo ESPECTRAL. A SVD decompõe o tensor em componentes de baixo rank, e cada componente ($\mathbf{U}_k$, $\mathbf{\Sigma}_k$, $\mathbf{V}_k^T$) é individualmente comprimido pela transformada TGL, criando compressão em cascata. O rank k é determinado adaptativamente pelo limiar de energia $1 - \alpha^2$.

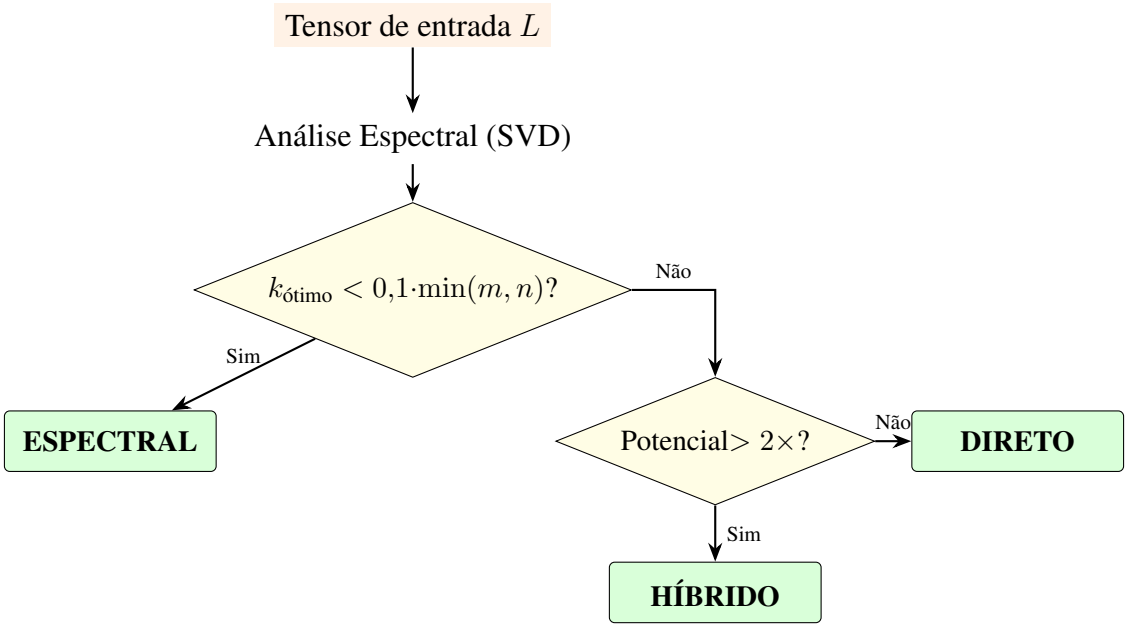


Figure 4: Algoritmo de seleção automática de modo (AUTO). A análise espectral via SVD determina o rank ótimo e o potencial de compressão, selecionando ESPECTRAL para tensores de baixo rank, HÍBRIDO para tensores com estrutura moderada, e DIRETO para tensores densos.

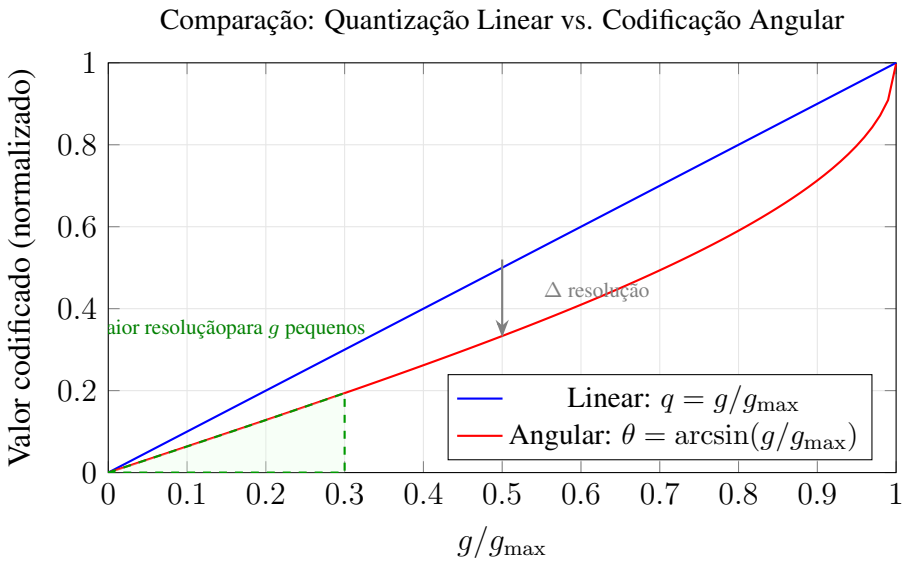


Figure 5: Comparação entre quantização linear ($q = g/g_{\max}$) e codificação angular ($\theta = \arcsin(g/g_{\max})$). A função $\arcsin$ é côncava, concentrando mais níveis de quantização na região de valores pequenos de g, onde gradientes, coeficientes espectrais e dados esparsos possuem maior densidade informacional. Para $g/g_{\max} < 0{,}3$ (região verde), a codificação angular oferece aproximadamente 1,5× mais resolução que a linear.

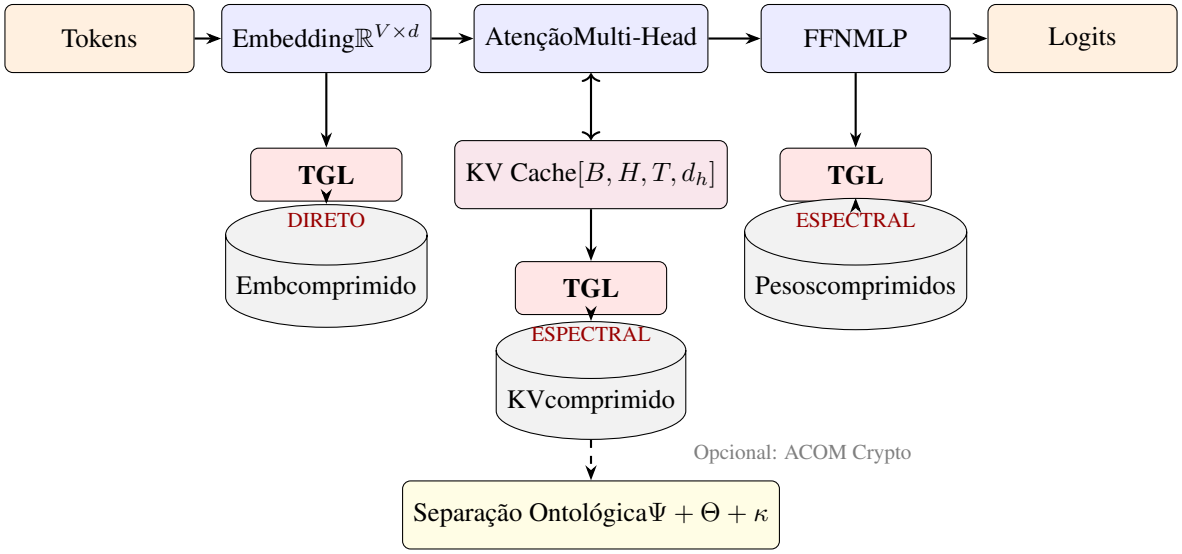


Figure 6: Integração do TGL-Tensor com pipeline de inferência LLM. Cada tipo de tensor recebe o modo de compressão ótimo: DIRETO para embeddings (baixa dimensionalidade), ESPECTRAL para KV cache e pesos (estrutura de baixo rank). Opcionalmente, a separação ontológica (ACOM Crypto) pode ser aplicada para armazenamento seguro.

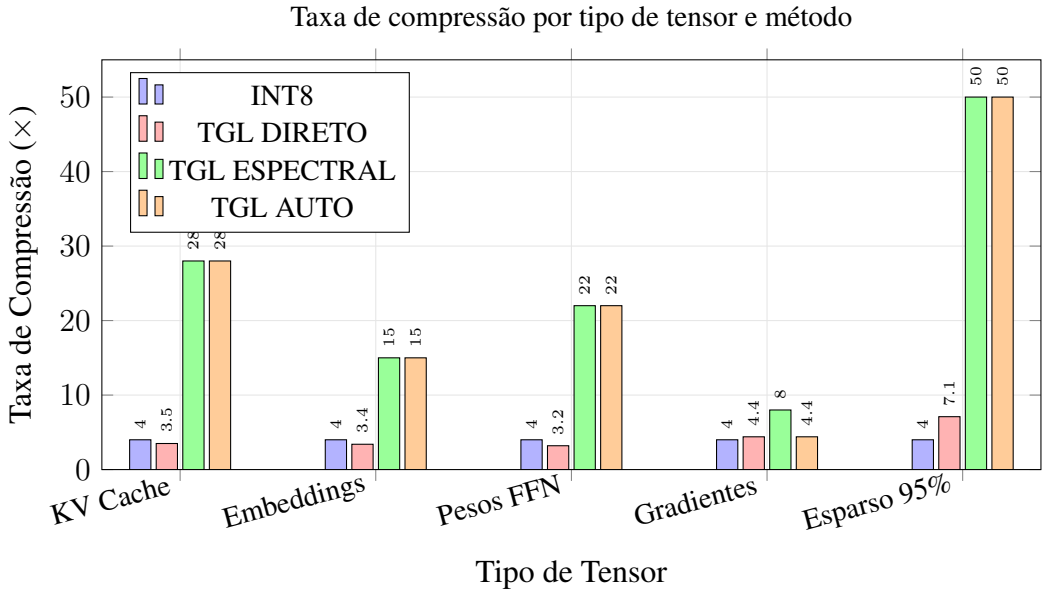


Figure 7: Taxa de compressão comparativa entre INT8 e os modos TGL (DIRETO, ESPECTRAL, AUTO) para diferentes tipos de tensores de LLM. O modo ESPECTRAL explora a estrutura de baixo rank presente em KV cache (28×) e pesos de FFN (22×), superando INT8 em até 7×. Para dados esparsos (95% de zeros), o modo ESPECTRAL atinge 50×. O modo AUTO seleciona automaticamente o melhor método por tensor.

Descrição da invenção

[20] A presente invenção compreende um método e sistema de compressão ontológica de tensores, denominado **TGL-Tensor**, que opera em quatro modos distintos, selecionáveis automaticamente ou manualmente.

Modo DIRETO

[21] O modo DIRETO aplica a transformada gravitacional diretamente sobre o tensor achatado:

$$g = \sqrt{|L|} \quad \text{(extração do gráviton)} \tag{1}$$

$$s = \text{sign}(L) \quad \text{(extração da fase)} \tag{2}$$

$$\theta = \arcsin\left(\frac{g}{g_{\max}}\right) \quad \text{(codificação angular)} \tag{3}$$

$$\theta_q = \text{round}\left(\frac{\theta}{\pi/2} \times (2^b - 1)\right) \quad \text{(quantização em } b \text{ bits)} \tag{4}$$

[22] A reconstrução é executada por Dobra Dimensional:

$$L' = s \times \left(g_{\max} \times \sin\left(\frac{\theta_q}{2^b - 1} \times \frac{\pi}{2}\right)\right)^2 \tag{5}$$