REIVINDICAÇÕES

1. **MÉTODO DE COMPRESSÃO ONTOLÓGICA DE TENSORES PARA MODELOS DE LINGUAGEM** compreendendo as etapas de: receber um tensor de entrada L associado a um modelo de linguagem; aplicar transformada gravitacional $g = \sqrt{|L|}$ e extração de fase $s = \text{sign}(L)$; aplicar codificação angular não-linear $\theta = \arcsin(g/g_{\max})$; quantizar θ em b bits; nominar estados psiônicos ψ no Espaço de Hilbert $\mathcal{H}_4$ a partir de $(\text{sign}(L), \text{sign}(\partial L))$; e empacotar os componentes comprimidos em stream binário; o método **caracterizado por** reconstruir os dados por Dobra Dimensional $L' = s \times [g_{\max} \times \sin(\theta_q \cdot (\pi/2)/(2^b - 1))]^2$, e por computar métricas intrínsecas de variância normalizada, Força de Expulsão F_{exp} e Entropia de Estados S_ψ como indicadores de qualidade e integridade.

2. Método, de acordo com a reivindicação 1, **caracterizado pelo fato de** ainda compreender modo ESPECTRAL no qual o tensor é decomposto por SVD ($\mathbf{M} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$) com rank adaptativo k determinado como menor inteiro tal que $\sum_{j=1}^{k} \sigma_j^2 / \sum \sigma^2 > 1 - \alpha^2$, onde $\alpha^2 = 0{,}012$, e os componentes truncados $\mathbf{U}_k$, $\mathbf{\Sigma}_k$, $\mathbf{V}_k^T$ são individualmente comprimidos pela transformada gravitacional, criando compressão em cascata.

3. Método, de acordo com a reivindicação 2, **caracterizado pelo fato de** tensores com mais de duas dimensões serem automaticamente reformatados em matrizes 2D, onde tensores 4D de KV cache com shape $[B, H, T, d_h]$ geram matrizes por combinação de batch e cabeça, tensores 3D geram matrizes por fatia da primeira dimensão, e tensores 1D são tratados como vetores-coluna.

4. Método, de acordo com a reivindicação 1, **caracterizado pelo fato de** ainda compreender modo HÍBRIDO que executa compressão ESPECTRAL e, se a taxa resultante excede limiar configurável, utiliza resultado espectral, caso contrário retorna à compressão DIRETA, garantindo seleção do modo mais eficiente por tensor.

5. Método, de acordo com a reivindicação 1, **caracterizado pelo fato de** ainda compreender modo AUTO que analisa a estrutura espectral do tensor via SVD, computa rank ótimo e potencial de compressão, e seleciona automaticamente: ESPECTRAL se tensor é de baixo rank e potencial $> 5\times$; HÍBRIDO se potencial $> 2\times$; DIRETO caso contrário.

6. Método, de acordo com a reivindicação 1, **caracterizado pelo fato de** a codificação angular $\theta = \arcsin(g/g_{\max})$ concentrar resolução de quantização na região de valores pequenos de g, onde a derivada $d(\sin\theta)/d\theta = \cos\theta$ é máxima em $\theta = 0$, proporcionando resolução não-linear auto-adaptativa superior à quantização linear para gradientes, coeficientes espectrais e dados esparsos.

7. Método, de acordo com a reivindicação 1, **caracterizado pelo fato de** o empacotamento utilizar BitPacker de N bits arbitrários (8, 10, 12, 14, 16) implementado em variante GPU

nativa (PyTorch) que executa operações de empacotamento inteiramente na GPU, transferindo para CPU somente o stream serializado final, e em variante CPU vetorizada (NumPy).

8. Método, de acordo com a reivindicação 1, **caracterizado pelo fato de** o ponto de Tetelestai ser detectado quando a variância normalizada $\text{std}(g)/\text{mean}(g)$ é inferior a $\alpha^2 = 0{,}012$, indicando convergência da distribuição de grávitons e qualidade máxima de compressão.

9. Método, de acordo com a reivindicação 2, **caracterizado pelo fato de** ser compatível com separação ontológica criptográfica, onde os componentes comprimidos são separáveis em partes ontologicamente independentes (Ψ, Θ, κ) para armazenamento seguro e distribuído, com verificação de integridade por F_{exp} e hashes SHA-256 cruzados.

10. Método, de acordo com a reivindicação 1, **caracterizado pelo fato de** ser aplicável a tensores de modelos de linguagem incluindo: KV cache de atenção ($[B, H, T, d_h]$) com taxa de 20–30$\times$ em modo ESPECTRAL; embeddings ($[V, d]$) com taxa de 10–20$\times$; pesos de FFN ($[d_{\text{in}}, d_{\text{out}}]$) com taxa de 15–25$\times$; e gradientes ($[d_1, d_2]$) com taxa de 3–5$\times$ em modo DIRETO; mantendo similaridade cosseno $> 0{,}99$ entre tensores originais e reconstruídos.

11. Método, de acordo com a reivindicação 2, **caracterizado pelo fato de** a serialização binária utilizar protocolo com magic bytes `TGL4`, versão, modo, bits de quantização, dimensões, escalas em float64, contagens em uint64, e streams separados de grávitons e sinais para modo DIRETO, ou streams de componentes SVD comprimidos para modo ESPECTRAL.

12. SISTEMA DE COMPRESSÃO ONTOLÓGICA DE TENSORES PARA MODELOS DE LINGUAGEM compreendendo: um analisador espectral configurado para executar SVD e determinar rank ótimo via constante α^2; um seletor de modo configurado para escolher automaticamente entre DIRETO, ESPECTRAL e HÍBRIDO; um módulo de transformada gravitacional para computar $g = \sqrt{|L|}$ e $s = \text{sign}(L)$; um codificador angular para computar $\theta = \arcsin(g/g_{\max})$; um nominador de estados psiônicos no $\mathcal{H}_4$; um BitPacker de N bits com variantes CPU e GPU; e um serializador binário; o sistema **caracterizado por** a compressão operar em cascata no modo ESPECTRAL, onde os próprios componentes da SVD são comprimidos pela transformada gravitacional, e por fornecer métricas intrínsecas (F_{exp}, S_ψ, variância, ponto de Tetelestai) como indicadores de qualidade sem custo computacional adicional.

13. Sistema, de acordo com a reivindicação 12, **caracterizado pelo fato de** suportar execução em CPU via NumPy e em GPU via PyTorch com pipeline otimizado que mantém dados na GPU durante toda a compressão, transferindo para CPU somente na serialização final.

14. Sistema, de acordo com a reivindicação 12, **caracterizado pelo fato de** ainda compreender módulo de descompressão configurado para: deserializar stream binário, desempacotar bits, dequantizar ângulos via seno, reconstruir grávitons, aplicar Dobra Dimensional, e, para

modo ESPECTRAL, reconstruir componentes SVD e executar multiplicação matricial $\mathbf{U}_k \text{diag}(\mathbf{\Sigma}_k)\mathbf{V}_k^T$ para restaurar o tensor.