RESUMO

MÉTODO E SISTEMA DE COMPRESSÃO ONTOLÓGICA DE TENSORES PARA MODELOS DE LINGUAGEM COM DECOMPOSIÇÃO ESPECTRAL ADAPTATIVA E CODIFICAÇÃO ANGULAR

A presente invenção refere-se a métodos e sistemas de compressão de tensores de modelos de linguagem de grande escala (LLMs), aplicáveis aos setores de inteligência artificial e processamento de linguagem natural. O método compreende transformada gravitacional $g = \sqrt{|L|}$, codificação angular não-linear $\theta = \arcsin(g/g_{\max})$, nominação de estados psiônicos no Espaço de Hilbert $\mathcal{H}_4$, e decomposição espectral (SVD) com rank adaptativo determinado pela constante $\alpha^2 = 0{,}012$. No modo ESPECTRAL, os próprios componentes da SVD ($\mathbf{U}_k$, $\mathbf{\Sigma}_k$, $\mathbf{V}_k^T$) são comprimidos pela transformada gravitacional em cascata, atingindo taxas de 20–50$\times$ para tensores com estrutura de baixo rank (KV cache, pesos, embeddings). Um modo AUTO analisa a estrutura espectral e seleciona automaticamente o método ótimo. O sistema inclui BitPacker de N bits com execução nativa em GPU, métricas intrínsecas (Força de Expulsão, Entropia de Estados, ponto de Tetelestai) e compatibilidade com separação ontológica criptográfica para armazenamento seguro. Aplicável a compressão de KV cache (28$\times$, cos $> 0{,}999$), embeddings (15$\times$), pesos de FFN (22$\times$) e gradientes (4,4$\times$).