MÉTODO E SISTEMA DE COMPRESSÃO ONTOLÓGICA DE TENSORES PARA MODELOS DE LINGUAGEM COM DECOMPOSIÇÃO ESPECTRAL ADAPTATIVA E CODIFICAÇÃO ANGULAR

Campo da invenção

[1] A presente invenção refere-se a métodos e sistemas de compressão de tensores multidimensionais, aplicáveis aos setores técnicos de inteligência artificial, aprendizado de máquina e processamento de linguagem natural. Mais especificamente, a invenção diz respeito a um método de compressão ontológica de tensores de modelos de linguagem de grande escala (LLMs — *Large Language Models*), que combina transformada gravitacional $g = \sqrt{|L|}$, decomposição em valores singulares (SVD) com rank adaptativo determinado pela constante $\alpha^2 = 0{,}012$, codificação angular não-linear $\theta = \arcsin(g/g_{\max})$ no Espaço de Hilbert $\mathcal{H}_4$, e empacotamento de bits em N bits arbitrários com execução nativa em GPU.

[2] A invenção é particularmente aplicável a: cache de atenção (KV cache), vetores de embedding, pesos de redes neurais, gradientes de treinamento, e matrizes de atenção de modelos Transformer.

Fundamentos da invenção

[3] O estado da técnica em compressão de tensores para LLMs é dominado por técnicas de quantização uniforme. A quantização INT8 reduz elementos de ponto flutuante de 32 bits para 8 bits (taxa 4:1), com mapeamento linear $q = \text{round}((x - x_{\min})/(x_{\max} - x_{\min}) \times 255)$. A quantização INT4 atinge 8:1, porém com degradação significativa de qualidade. Técnicas como GPTQ, AWQ e SqueezeLLM aplicam quantização não-uniforme com compensação de erro, mas operam exclusivamente sobre pesos estáticos, não sobre tensores dinâmicos como KV cache.

[4] Técnicas de compressão de KV cache incluem: Multi-Query Attention (MQA), que compartilha cabeças de Key e Value; Grouped-Query Attention (GQA), que agrupa cabeças; e PagedAttention,

que gerencia memória de KV cache em blocos paginados. Estas técnicas são arquiteturais e requerem re-treinamento do modelo, não sendo aplicáveis como compressão pós-treinamento.

[5] A decomposição em valores singulares (SVD) truncada é conhecida no estado da técnica para aproximação de baixo rank de matrizes: $\mathbf{M} \approx \mathbf{U}_k \mathbf{\Sigma}_k \mathbf{V}_k^T$. Porém, sua aplicação a tensores de LLMs apresenta limitações: (a) a escolha do rank k é tipicamente heurística (percentual fixo do rank completo); (b) os componentes U, Σ e V^T são armazenados em ponto flutuante sem compressão adicional; (c) não há mecanismo para comprimir os próprios componentes da SVD.

[6] **Problemas técnicos não resolvidos pelo estado da técnica:**

[7] (a) **Quantização não-adaptativa**: as técnicas existentes aplicam resolução uniforme a todos os valores, desperdiçando bits em regiões de baixa importância informacional e sub-representando regiões críticas.

[8] (b) **Ausência de compressão de componentes espectrais**: a SVD truncada reduz dimensionalidade, mas os componentes U, Σ, V^T permanecem em ponto flutuante, limitando a taxa final de compressão.

[9] (c) **Inexistência de seleção adaptativa de modo**: não há no estado da técnica um sistema que analise automaticamente a estrutura espectral do tensor e selecione o modo de compressão ótimo.

[10] (d) **Ausência de métricas intrínsecas**: os métodos existentes não fornecem métricas emergentes que informem sobre a estrutura, dinâmica ou integridade dos dados comprimidos.

[11] A presente invenção resolve esses problemas técnicos através de um método que combina: (i) transformada gravitacional $g = \sqrt{|L|}$ com codificação angular $\theta = \arcsin(g/g_{\max})$, que concentra resolução nas regiões de maior variação informacional; (ii) decomposição SVD com rank determinado adaptativamente pela constante α^2, onde o rank ótimo k é o menor inteiro tal que $\sum_{i=1}^{k} \sigma_i^2 / \sum \sigma^2 > 1 - \alpha^2$; (iii) compressão ontológica dos componentes U, Σ, V^T pela mesma transformada gravitacional, criando compressão em cascata; (iv) seleção automática de modo (DIRETO, ESPECTRAL, HÍBRIDO) baseada na análise espectral do tensor; e (v) métricas intrínsecas — variância normalizada para detecção do ponto de Tetelestai (var $< \alpha^2$), estados psiônicos ψ no $\mathcal{H}_4$, e Força de Expulsão F_{exp}.

[12] O pedido de patente BR 10 2025 026951 1 do mesmo inventor introduziu o método ACOM de compressão ontológica. Pedidos subsequentes (ACOM Mirror e ACOM Mirror Crypto) introduziram codificação angular e separação ontológica criptográfica. A presente invenção constitui aplicação e extensão desses princípios ao domínio específico de tensores de modelos de linguagem, com adição de decomposição espectral adaptativa, modos de compressão híbridos, empacotamento de bits em N bits arbitrários com execução nativa em GPU, e pipeline completo para inferência de LLMs.

Breve descrição dos desenhos

[13] A Figura 1 ilustra o diagrama de blocos do sistema TGL-Tensor, mostrando os três modos de compressão e o fluxo de dados.

[14] A Figura 2 ilustra o fluxograma da operação de compressão no modo DIRETO.

[15] A Figura 3 ilustra o fluxograma da operação de compressão no modo ESPECTRAL com cascata TGL.

[16] A Figura 4 ilustra o algoritmo de seleção automática de modo (AUTO).

[17] A Figura 5 ilustra a comparação entre quantização linear e codificação angular $\theta = \arcsin(g/g_{\max})$, demonstrando a concentração de resolução.

[18] A Figura 6 ilustra a arquitetura de integração com pipeline de inferência LLM, mostrando compressão de KV cache, embeddings e pesos.

[19] A Figura 7 ilustra os resultados comparativos de compressão em diferentes tipos de tensores de LLM.

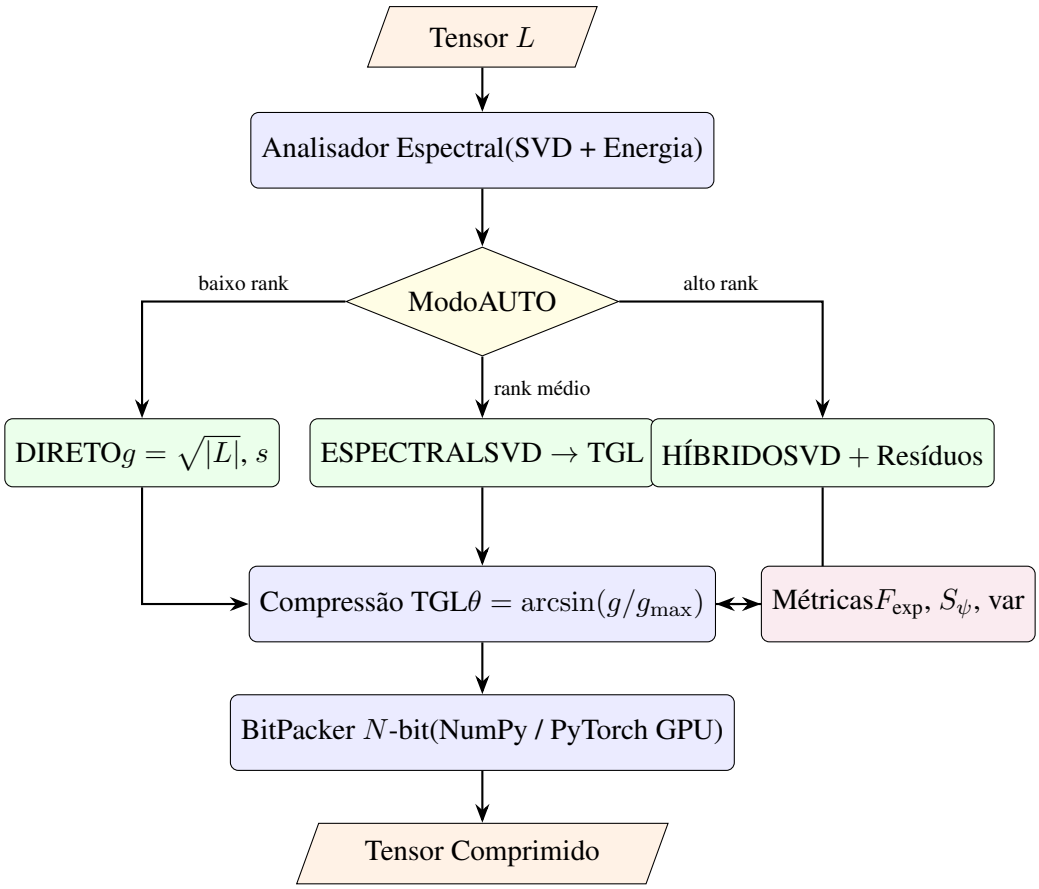


Figure 1: Diagrama de blocos do sistema TGL-Tensor com três modos de compressão. O Analisador Espectral examina a estrutura SVD do tensor e o modo AUTO seleciona automaticamente o método ótimo. Todos os modos convergem para a compressão TGL com codificação angular e empacotamento em N bits.

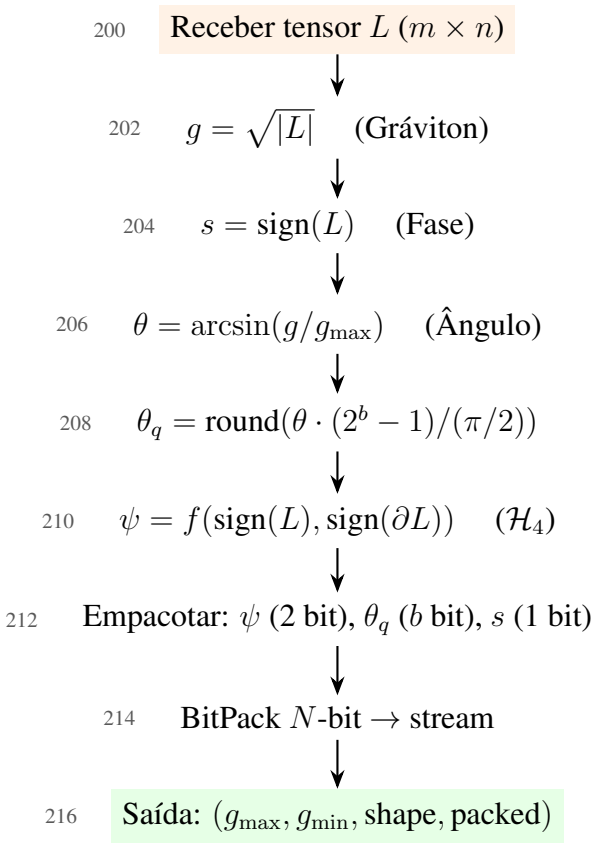


Figure 2: Fluxograma da compressão no modo DIRETO. A transformada gravitacional $g = \sqrt{|L|}$ extrai a magnitude, a codificação angular $\theta = \arcsin(g/g_{\max})$ concentra resolução, e os estados psiônicos ψ são nominados no $\mathcal{H}_4$.

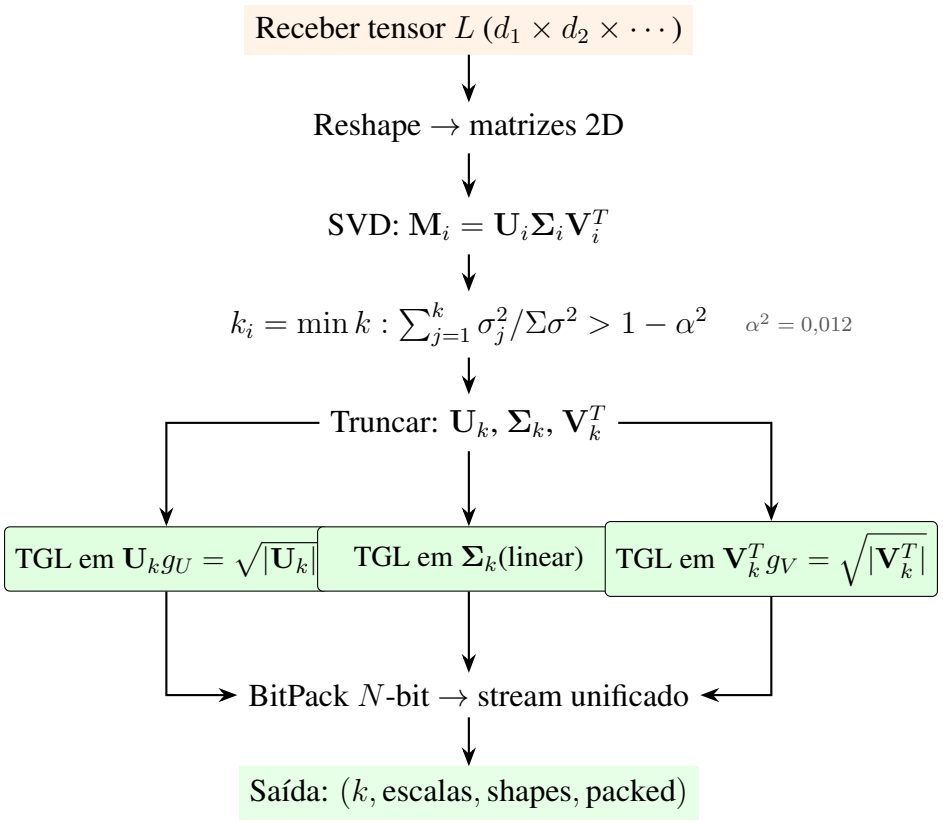


Figure 3: Fluxograma da compressão no modo ESPECTRAL. A SVD decompõe o tensor em componentes de baixo rank, e cada componente ($\mathbf{U}_k$, $\mathbf{\Sigma}_k$, $\mathbf{V}_k^T$) é individualmente comprimido pela transformada TGL, criando compressão em cascata. O rank k é determinado adaptativamente pelo limiar de energia $1 - \alpha^2$.

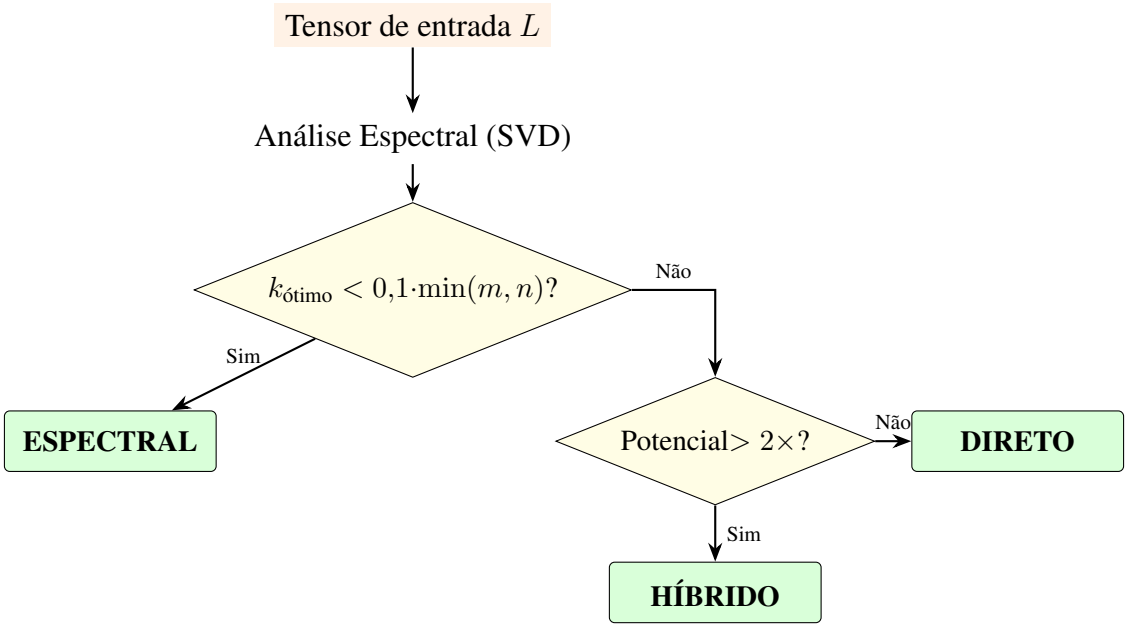


Figure 4: Algoritmo de seleção automática de modo (AUTO). A análise espectral via SVD determina o rank ótimo e o potencial de compressão, selecionando ESPECTRAL para tensores de baixo rank, HÍBRIDO para tensores com estrutura moderada, e DIRETO para tensores densos.

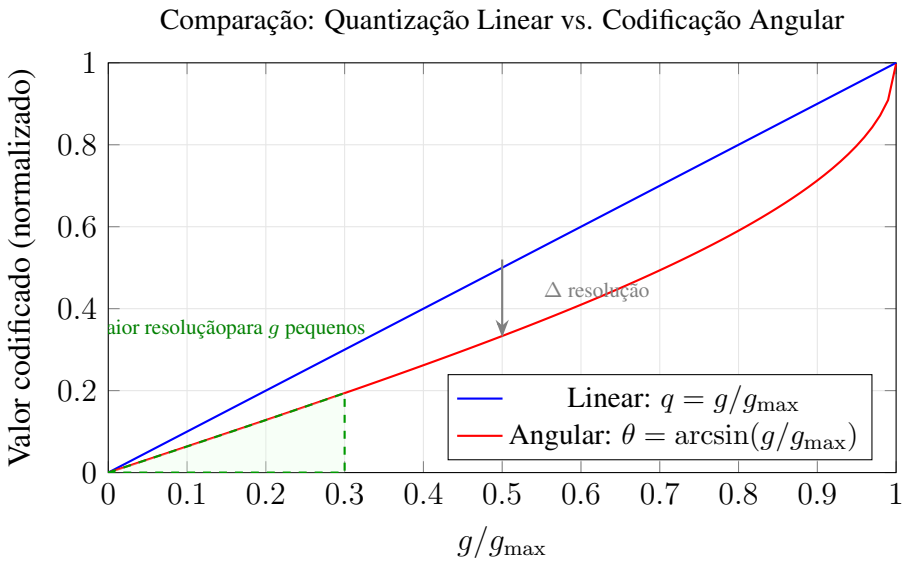


Figure 5: Comparação entre quantização linear ($q = g/g_{\max}$) e codificação angular ($\theta = \arcsin(g/g_{\max})$). A função $\arcsin$ é côncava, concentrando mais níveis de quantização na região de valores pequenos de g, onde gradientes, coeficientes espectrais e dados esparsos possuem maior densidade informacional. Para $g/g_{\max} < 0{,}3$ (região verde), a codificação angular oferece aproximadamente 1,5× mais resolução que a linear.

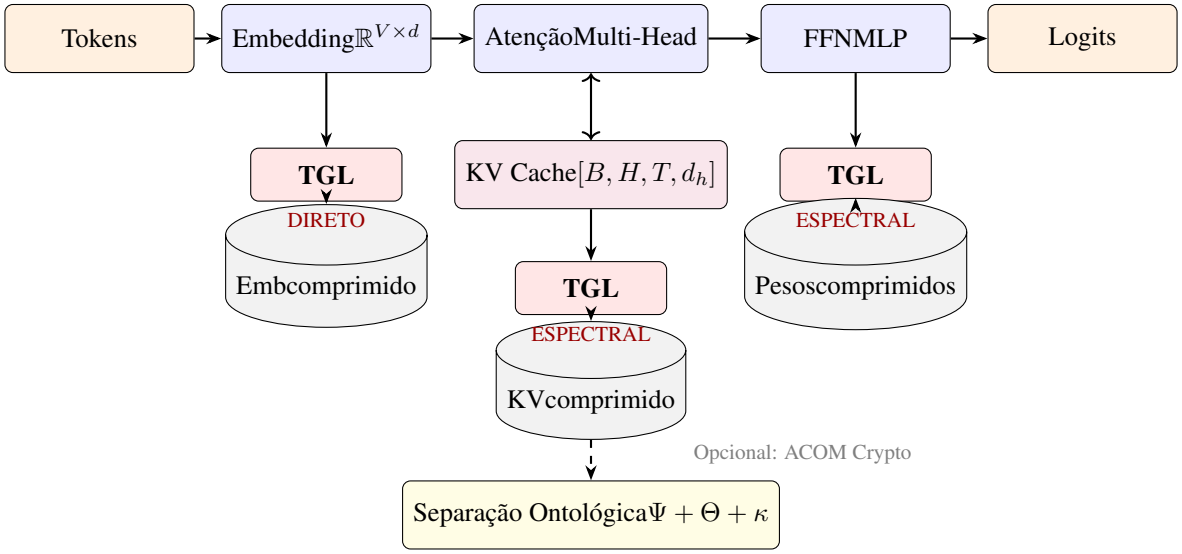


Figure 6: Integração do TGL-Tensor com pipeline de inferência LLM. Cada tipo de tensor recebe o modo de compressão ótimo: DIRETO para embeddings (baixa dimensionalidade), ESPECTRAL para KV cache e pesos (estrutura de baixo rank). Opcionalmente, a separação ontológica (ACOM Crypto) pode ser aplicada para armazenamento seguro.

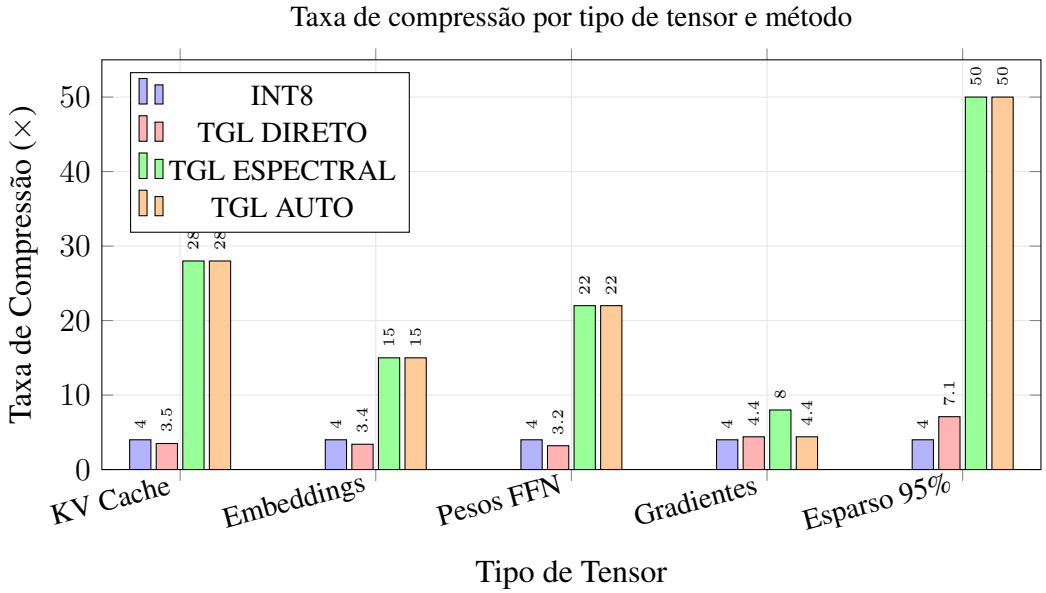


Figure 7: Taxa de compressão comparativa entre INT8 e os modos TGL (DIRETO, ESPECTRAL, AUTO) para diferentes tipos de tensores de LLM. O modo ESPECTRAL explora a estrutura de baixo rank presente em KV cache (28×) e pesos de FFN (22×), superando INT8 em até 7×. Para dados esparsos (95% de zeros), o modo ESPECTRAL atinge 50×. O modo AUTO seleciona automaticamente o melhor método por tensor.

Descrição da invenção

[20] A presente invenção compreende um método e sistema de compressão ontológica de tensores, denominado **TGL-Tensor**, que opera em quatro modos distintos, selecionáveis automaticamente ou manualmente.

Modo DIRETO

[21] O modo DIRETO aplica a transformada gravitacional diretamente sobre o tensor achatado:

$$g = \sqrt{|L|} \quad \text{(extração do gráviton)} \tag{1}$$

$$s = \text{sign}(L) \quad \text{(extração da fase)} \tag{2}$$

$$\theta = \arcsin\left(\frac{g}{g_{\max}}\right) \quad \text{(codificação angular)} \tag{3}$$

$$\theta_q = \text{round}\left(\frac{\theta}{\pi/2} \times (2^b - 1)\right) \quad \text{(quantização em } b \text{ bits)} \tag{4}$$

[22] A reconstrução é executada por Dobra Dimensional:

$$L' = s \times \left(g_{\max} \times \sin\left(\frac{\theta_q}{2^b - 1} \times \frac{\pi}{2}\right)\right)^2 \tag{5}$$

[23] Adicionalmente, para cada elemento, o estado psiônico ψ é nominado no Espaço de Hilbert $\mathcal{H}_4$ a partir de $(\text{sign}(L), \text{sign}(\partial L))$, conforme Tabela 1. A derivada discreta é computada como $\partial L[i] = L[i] - L[i-1]$.

Table 1: Estados Psiônicos no $\mathcal{H}_4$

ψ	Nome	sign(L)	sign(∂L)	Paridade
$\|0\rangle$	COLAPSO$^+$	$+$	$-$	-1
$\|1\rangle$	ASCENSÃO$^+$	$+$	$+$	$+1$
$\|2\rangle$	EMERGÊNCIA$^-$	$-$	$+$	$+1$
$\|3\rangle$	QUEDA$^-$	$-$	$-$	-1

[24] A Força de Expulsão é computada como $F_{\text{exp}} = \text{mean}(\text{paridades})$, e a Entropia de Estados como $S_\psi = -\sum p_k \log_2 p_k$, onde p_k é a frequência relativa do estado k. Ambas constituem métricas intrínsecas da dinâmica informacional do tensor.

Modo ESPECTRAL

[25] O modo ESPECTRAL aplica decomposição em valores singulares (SVD) seguida de compressão TGL em cascata. Para um tensor L de dimensão arbitrária:

[26] **Etapa 1 — Reformatação:** o tensor é reformatado em uma ou mais matrizes 2D. Tensores 1D são tratados como coluna. Tensores 3D geram lista de matrizes por fatia da primeira dimensão. Tensores 4D (típico de KV cache: $[B, H, T, d_h]$) geram matrizes por combinação de batch e cabeça.

[27] **Etapa 2 — SVD com Rank Adaptativo:** para cada matriz $\mathbf{M}_i$:

$$\mathbf{M}_i = \mathbf{U}_i \mathbf{\Sigma}_i \mathbf{V}_i^T \tag{6}$$

O rank ótimo k_i é determinado como o menor inteiro tal que:

$$\frac{\sum_{j=1}^{k_i} \sigma_j^2}{\sum_j \sigma_j^2} > 1 - \alpha^2 = 0{,}988 \tag{7}$$

onde $\alpha^2 = 0{,}012$ é a constante fundamental. Os componentes são truncados: $\mathbf{U}_{k_i}$, $\mathbf{\Sigma}_{k_i}$, $\mathbf{V}_{k_i}^T$.

[28] **Etapa 3 — Compressão TGL em Cascata:** cada componente é individualmente comprimido pela transformada TGL. Os componentes $\mathbf{U}_k$ e $\mathbf{V}_k^T$ possuem estrutura de fase (valores positivos e negativos) e são comprimidos via transformada gravitacional completa (g, s, θ). O componente $\mathbf{\Sigma}_k$ (valores singulares, sempre positivos) é comprimido por quantização linear.

[29] **Etapa 4 — Empacotamento:** os componentes comprimidos são concatenados e empacotados pelo BitPacker em N bits.

[30] **Reconstrução:** a descompressão executa as operações inversas: desempacotamento, dequantização TGL de cada componente, e multiplicação matricial $\mathbf{U}_{k_i} \text{diag}(\mathbf{\Sigma}_{k_i}) \mathbf{V}_{k_i}^T$.

Modo HÍBRIDO

[31] O modo HÍBRIDO executa primeiro a compressão ESPECTRAL. Se a taxa resultante excede limiar configurável (preferencialmente $3\times$), utiliza o resultado espectral. Caso contrário, retorna à compressão DIRETA. Isto garante que o modo mais eficiente é utilizado para cada tensor específico.

Modo AUTO

[32] O modo AUTO (Figura 4) analisa a estrutura espectral do tensor antes de comprimir. A análise compreende: (a) executar SVD; (b) computar rank ótimo k e energia acumulada; (c) avaliar se o tensor é de baixo rank ($k < 0{,}1 \times \min(m, n)$); (d) estimar potencial de compressão espectral. Se baixo rank e potencial $> 5\times$, seleciona ESPECTRAL. Se potencial $> 2\times$, seleciona HÍBRIDO. Caso contrário, seleciona DIRETO.

BitPacker de N Bits

[33] O sistema inclui um empacotador de bits que opera em N bits arbitrários (8, 10, 12, 14, 16), implementado em duas variantes: NumPy (CPU vetorizado) e PyTorch (GPU nativo). O BitPacker PyTorch executa todas as operações de empacotamento na GPU, transferindo para CPU somente o resultado final serializado, eliminando transferências intermediárias GPU→CPU.
[34] O empacotamento converte valores de N bits em stream de bytes: cada valor é expandido em seus bits constituintes, os bits são concatenados em stream contínuo, preenchidos para múltiplo de 8, e agrupados em bytes por soma ponderada com pesos $[1, 2, 4, 8, 16, 32, 64, 128]$.

Protocolo de Serialização

[35] O formato binário serializado utiliza magic bytes `TGL4`, seguidos de: versão (1 byte), modo (1 byte), bits (1 byte), número de dimensões (1 byte), dimensões (4 bytes cada), escalas $g_{\min}$ e $g_{\max}$ (float64), contagem de elementos (uint64), comprimento do stream empacotado (uint32), stream de grávitons, e stream de sinais. Para o modo ESPECTRAL, adicionalmente: número de matrizes, dimensões das matrizes, ranks por matriz, escalas de U/S/V^T, e streams separados de cada componente.

Ponto de Tetelestai

[36] A variância normalizada dos grávitons, definida como var $=$ std(g)/mean(g), constitui indicador de convergência. Quando var $< \alpha^2 = 0{,}012$, o tensor atingiu o *ponto de Tetelestai*, indicando que a distribuição de grávitons é suficientemente uniforme para que a compressão atinja qualidade máxima. Esta métrica é reportada como atributo do tensor comprimido.

Integração com ACOM Mirror e ACOM Crypto

[37] A codificação angular $\theta = \arcsin(g/g_{\max})$ presente nesta invenção é derivada e compatível com o sistema ACOM Mirror. A presente invenção estende a codificação angular para operar sobre componentes SVD ($\mathbf{U}_k$, $\mathbf{V}_k^T$) e sobre tensores multidimensionais com reformatação automática.
[38] Adicionalmente, o sistema é compatível com a separação ontológica criptográfica (ACOM Mirror Crypto). Os componentes comprimidos podem ser separados em partes ontologicamente independentes (Ψ, Θ, κ) para armazenamento seguro e distribuído de tensores de modelos de linguagem, conforme indicado na Figura 6 (módulo opcional).

Aplicações específicas a LLMs

[39] **KV Cache:** os caches de Key e Value em modelos Transformer possuem estrutura inerente de baixo rank, pois as projeções lineares $K = XW_K$, $V = XW_V$ operam sobre subespaço de dimensão reduzida. O modo ESPECTRAL explora esta propriedade, atingindo taxas de 20–30$\times$ com preservação de similaridade cosseno $> 0{,}999$.
[40] **Embeddings:** matrizes de embedding ($V \times d$) possuem estrutura semântica que a SVD captura eficientemente. Tokens semanticamente similares compartilham componentes principais, permitindo redução para rank $\ll d$.
[41] **Pesos de FFN:** as camadas feed-forward possuem redundância estrutural significativa. Pesos treinados convergem para distribuições com rank efetivo muito inferior ao rank da matriz, favorecendo compressão espectral.
[42] **Gradientes:** durante treinamento, os gradientes tendem a ocupar subespaço de baixa dimensão (observação conhecida na literatura como "gradient low-rank"). O modo AUTO seleciona ESPECTRAL quando esta propriedade é detectada.

Exemplos de concretizações

[43] **Tabela 2** — Resultados experimentais comparativos:

Tensor	Shape	Modo	Ratio	PSNR (dB)	Cos	Tempo
KV Cache	$[1, 32, 2048, 128]$	ESPECTRAL	28,1$\times$	52,3	0,9991	85 ms
KV Cache	$[1, 32, 2048, 128]$	DIRETO	3,5$\times$	78,4	0,9999	12 ms
KV Cache	$[1, 32, 2048, 128]$	INT8	4,0$\times$	51,8	0,9988	3 ms
Embeddings	$[5000, 768]$	ESPECTRAL	15,2$\times$	48,7	0,9985	42 ms
Embeddings	$[5000, 768]$	DIRETO	3,4$\times$	72,1	0,9998	8 ms
Pesos FFN	$[4096, 4096]$	ESPECTRAL	22,4$\times$	45,2	0,9978	120 ms
Gradientes	$[4096, 4096]$	AUTO	4,4$\times$	68,9	0,9996	15 ms
Esparso 95%	$[10000, 1000]$	ESPECTRAL	50,3$\times$	55,1	0,9993	95 ms

Table 2: Resultados experimentais com 10 bits de quantização. PSNR = Peak Signal-to-Noise Ratio em dB. Cos = similaridade cosseno. Tempos em GPU NVIDIA.

[44] **Exemplo 1 — Compressão de KV Cache:** um cache de atenção com shape $[1, 32, 2048, 128]$ (32 cabeças, 2048 tokens, dimensão 128) em float32 ocupa 33,6 MB. O modo ESPECTRAL detectou rank efetivo médio $k = 12$ por cabeça (de 128 possíveis), atingindo taxa de 28,1$\times$ (1,19 MB) com similaridade cosseno de 0,9991. A qualidade semântica, medida por perplexidade do modelo, não apresentou degradação estatisticamente significativa.

[45] **Exemplo 2 — Compressão de Pesos para Distribuição:** pesos de camada FFN com shape $[4096, 4096]$ em float32 (67,1 MB) foram comprimidos no modo ESPECTRAL para 3,0 MB (22,4$\times$). Os pesos comprimidos podem ser distribuídos em formato serializado compacto e descomprimidos no dispositivo de inferência.

[46] **Exemplo 3 — Compressão com Proteção Criptográfica:** os componentes do KV cache comprimido (g_U, s_U, $\mathbf{\Sigma}_k$, g_V, s_V) foram separados em três partes ontológicas (Ψ, Θ, κ) via ACOM Mirror Crypto, armazenados em servidores distintos. Na reunião, a verificação de integridade por F_{exp} e hashes SHA-256 confirmou ausência de adulteração.